3437766 - Availability of Generative AI Models

Component: CA-ML-AIC (Cross-Application Components > Machine Learning > SAP AI Core), Version: 86, Released On: 22.05.2025

Symptom

This SAP Note outlines the available models and their versions in different data centers, along with their deprecation dates. Furthermore, it details the conversion rates for GenAI Tokens for each model, and provides information on rate limits.

Solution

The information in the following table is subject to changes, in particular with respect to general availability and price. Futher information is provided after the table.

Exe cuta ble	cuta el	Ver sio n	Gen AI I npu	Gen AI O utp	Ava ilab le i	D ep re	Sug gest ed	Reti rem ent	Re	gion	Ava	ailab	oility	(SA	P A	Co1	e)					Rate Limit (req/
ID (Ac cess Typ e)			t To ken s (for 1,00 o M odel Tok ens)	ut T oke ns (for 1,00 o M odel Tok ens)	n O rch estr atio n	ca te d	lace me nt	Dat e	A P 1 O	A P 1	A P 2 0	A P 3 o	E U 1 O	E U 11	E U 2 0	E U 3 o	J P 1 0	U S 1 O	U S 2 1	U S 3 o	S A 3 o	min/t enant)
aicor e-mi stral ai (sap- host ed)	mistr alai mistr al-lar ge-in struct	240 7 (la test)	0.00	0.00 320	yes			not e arlie r tha n 20 25-0 6-30	Y es *				Y es	Y es	ye s	ye s	Y e s *	Y es *	ye s*	ye s*		100
aicor e-mi stral ai (s ap-h oste d)	mistr alai mistr al-sm all-in struct	250 3 (la test)	0.00	0.00 015	yes			not e arlie r tha n 20 25-0 9-30	Y es *	Y es *	Y es *	Y es *	Y es	Y es	Y es	Y es	Y e s *	Y es *	Y es *	Y es *		100
aicor e-ib m (sap- man aged)	ibm granit e-13b -chat	2.1. o (l ates t)	0.00	0.00	yes			not e arlie r tha n 20 25-0 6-30	Y es *				Y es	-	-	-	Y e s *	Y es	-	-		100
aicor e-op enso urce (sap- man aged)	meta- -llam a3.1-7 ob-in struct	202 409 (lat est)	0.00	0.00 217	yes			not e arlie r tha n 20 25-0 6-30	-				Y es	-	-	-	-	-	_	_		100

aicor e-op enso urce (sap- man aged)	mistr alai mixtr al-8x 7b-in struct -v01	null (lat est)	0.00	0.00	yes	tru e	not e arlie r tha n 20 25-0 5-30	-				Y es	-	-	-	-	-	-	-	y es	100
aicor e-nvi dia (sap- man aged)	nvidi alla ma-3. 2-nv- embe dqa-1 b	2 (l ates t)		-			not e arlie r tha n 20 25-0 9-30	Y es	Y es	Y es	Y es	Y es	Y es	Y es	Y es	Y e s	Y es	Y es	Y es		138
aws- bedr ock (AW S)	amaz onti tan-e mbed -text	1.2	0.00 014	-				Y es *				Y es *	Y es	Y es *	Y es *	Y e s *	Y es	Y es	Y es		50
aws- bedr ock (AWS	amaz onti tan-e mbed -text	2 (l ates t)	0.00 014	-				Y es	Y es	Y es	Y es	Y es	Y es	Y es	Y es	Y e s	Y es	Y es	Y es		138
aws- bedr ock (AW S)	amaz onti tan-te xt-ex press	1 (la test)	0.00 086	0.00 158	yes			Y es		Y es		Y es	Y es	Y es	Y es	Y e s *	Y es	Y es	Y es		50
aws- bedr ock (AW S)	amaz onti tan-te xt-lite		0.00	0.00 040	yes			Y es		Y es		Y es	Y es	Y es	Y es	Y e s *	Y es	Y es	Y es		50
aws- bedr ock (AW S)	amaz onn ova-p ro	1 (la test)	0.00 312	0.00 920	yes			-				-	-	-	-	-	Y es	Y es	Y es		50
aws- bedr ock (AW S)	amaz onn ova-li te	1 (la test)	0.00 312	0.00 920	yes			-				-	-	-	-	-	Y es	Y es	Y es		50
aws- bedr ock (AW S)	amaz onn ova- micro	1 (la test)	0.00 086	0.00 158	yes			-				-	-	-	-	-	Y es	Y es	Y es		50
aws- bedr ock (AW S)	anthr opic claud e-3-h aiku	1 (la test)	0.00 024	0.00 089	yes			Y es		Y es		Y es *	Y es	Y es *	Y es *	Y e s *	Y es	Y es	Y es		50

aws- bedr ock (AW S)	anthr opic claud e-3-s onnet	1 (la test)	0.00 204	0.00 988	yes				Y es		Y es		Y es	Y es	Y es	Y es	Y e s *	Y es	Y es	Y es		50
aws- bedr ock (AW S)	anthr opic claud e-3.5- sonne t	1	0.00	0.00 988	yes				Y es	Y es *			Y es	Y es	Y es *	Y es *	Y e s *	Y es	Y es	Y es		50
aws- bedr ock (AW S)	anthr opic claud e-3.5- sonne t	2 (l ates t)	0.00	0.00 988	yes				-				_	_	_	_	-	Y es	Y es	Y es		50
aws- bedr ock (AW S)	anthr opic claud e-3.7- sonne t	1	0.00	0.00 988	yes								ye s		ye s	ye s		ye s	ye s	ye s		100
aws- bedr ock (AW S)	anthr opic claud e-3-0 pus	1 (la test)	0.00 988	0.04 913	yes				Y es *				Y es *	-	Y es *	Y es *	Y e s *	Y es	Y es	Y es		50
azur e-op enai (Azu re)	text-e mbed ding- 3-larg e	1 (la test)	0.00	-				not e arlie r tha n 20 26-0 1-25	Y es *	Y es *	Y es *	Y es	Y es *	Y es	Y es *	Y es *	Y e s	Y es	Y es	Y es	Y es *	138
azur e-op enai (Azu re)	text-e mbed ding- 3-sm all	ı (la test)	0.00 002	-				not e arlie r tha n 20 26-0 1-25	Y es *				Y es *	Y es	Y es *	Y es *	Y e s *	Y es	Y es	Y es		138
azur e-op enai (Azu re)	text-e mbed ding- ada-o 02	2 (l ates t)	0.00	-		ye s	text- emb eddi ng-3 -sma ll text- emb eddi ng-3 -larg e	not e arlie r tha n 20 25-1 0-03	Y es	Y es *	Y es *	Y es *	Y es	Y es	Y es	Y es	Y e s	Y es	Y es *	Y es *	Y es *	600 (US10, EU10) , 138* all oth er lan dscape s
azur e-op enai (Azu re)	gpt-3 5-tur bo	110 6 (l ates t)	0.00 094	0.00	yes	ye s	gpt- 40- mini	not e arlie r tha n 20 25-0 5-31	Y es *				Y es	Y es	Y es	Y es	Y e s *	Y es	Y es	Y es		120

azur e-op enai (Azu re)	gpt-3 5-tur bo-01 25	012 5 (la test)	0.00 037	0.00 097	yes	ye s	gpt- 40- mini	not e arlie r tha n 20 25-0 5-31	-				Y es *	·-	-	-	-	Y es	-	-		120
azur e-op enai (Azu re)	gpt-4	061 3	0.01 735	0.03 462	yes	ye s	gpt- 40	202 5-06 -06	Y es	Y es *	Y es *	Y es *	Y es	Y es	Y es	Y es	Y e s	Y es	Y es *	Y es *	Y es *	78
azur e-op enai (Azu re)	gpt-4 -32k	061 3 (la test)	0.03 462	0.06 917	yes	ye s	gpt- 40	202 5-06 -06	Y es	Y es *	Y es *	Y es *	Y es	Y es	Y es	Y es	Y e s	Y es	Y es *	Y es *	Y es *	78
azur e-op enai (Azu re)	gpt-4 o	202 4-0 5-13	0.00 312	0.00 920	yes			not e arlie r tha n 20 25-0 6-30	Y es *	Y es *	Y es *	Y es *	Y es	Y es	Y es	Y es	Y e s *	Y es	Y es	Y es	Y es *	78
azur e-op enai (Azu re)	gpt-4 o	202 4-0 8-0 6 (l ates t)	0.00	0.00 616	yes			not e arlie r tha n 20 25-0 8-06	-				Y es	Y es	Y es	Y es	-	Y es	Y es	Y es		78
azur e-op enai (Azu re)	gpt-4 o	202 4-11 -20			yes								Y es	Y es	Y es	Y es	Y e s	Y es	Y es	Y es		78
azur e-op enai (Azu re)	gpt-4 o-mi ni	202 4-0 7-18	0.00	0.00 039	yes			not e arlie r tha n 20 25-0 7-18	Y es *			Y es	Y es	Y es	Y es	Y es	Y e s *	Y es	Y es	Y es	Y es *	120
azur e-op enai (Azu re)	gpt-4	turb 0-2 024 -04- 09 (lat est)	0.00 616	0.01 833	yes			not e arlie r tha n 20 25-0 6-06	Y es *				Y es	Y es	Y es *	Y es *	Y e s *	Y es	Y es	Y es		78
azur e-op enai (Azu re)	gpt-4.	202 5-0 4-14	0.00 129	0.00 494	yes				Y es *	Y es *	Y es *	Y es *	Y es	Y es	Y es	Y es	Y e s *	Y es	Y es	Y es		78
azur e-op enai (Azu re)	gpt-4. 1-min i	202 5-0 4-14	0.00 026	0.00 099	yes				Y es *	Y es *	Y es *	Y es *					Y e s *	Y es	Y es	Y es		120

azur e-op enai (Azu re)	gpt-4. 1-nan 0	202 5-0 4-14	0.00	0.00 026	yes				Y es *	Y es *	Y es *	Y es *	Y es	Y es	Y es	Y es	Y e s *	Y es	Y es	Y es	120
azur e-op enai (Azu re)	01	202 4-12 -17	0.00 920	0.03 658	yes			not e arlie r tha n 20 25-1 2-17	Y es *	Y es *	Y es *	Y es *					Y e s *	Y es *	Y es *	Y es *	78
azur e-op enai (Azu re)	o3-mi ni	202 5-01 -31	0.00 069	0.00 270	yes				Y es *	Y es *	Y es *	Y es *	Y es	Y es	Y es	Y es	Y e s *	Y es	Y es	Y es	120
azur e-op enai (Azu re)	03	202 5-0 4-16	0.00 610	0.02 436	yes				Y es *	Y es *	Y es *	Y es *					Y e s *	Y es *	Y es *	Y es *	78
azur e-op enai (Azu re)	o4-mi ni	202 5-0 4-16	0.00 069	0.00 270	yes				Y es *	Y es *	Y es *	Y es *					Y e s *	Y es *	Y es *	Y es *	120
gcp- verte xai (Goo gle)	gemi ni-1.5 -flash	001	0.00 007 (<12 8k to kens) 0.00 012 (>= 1 28k t oken s)	0.00 021 (< 12 8k c onte xt) 0.00 040 (>= 128k cont ext)	yes	ye s	gemi ni-2. o-fla sh-0 o1 gemi ni-2. o-fla sh-li te-0	202 5-05 -24	Y es *		ye s		Y es	_	Y es	Y es	Y e s *	Y es	Y es	Y es	100
gcp- verte xai (Goo gle)	gemi ni-1.5 -flash	002 (lat est)	0.00 007 (<12 8k to kens) 0.00 012 (>= 1 28k t oken s)	0.00 021 (< 12 8k c onte xt) 0.00 040 (>= 128k cont ext)	yes				-				Y es	-	Y es	Y es	-	Y es	_	Y es	100

gcp- verte xai (Goo gle)	gemi ni-1.5 -pro	001	0.00 087 (<12 8k to kens) 0.00 167 (>= 1 28k t oken s)	0.00 327 (< 12 8k c onte xt) 0.00 647 (>= 1 28k cont ext)	yes	ye s	gemi ni-2. O-fla sh-0 01 gemi ni-2. O-fla sh-li te-0	202 5-05 -24	Y es *		Y es	Y es	-	Y es	Y es	Y e s *	Y es	Y es	Y es	100
gcp- verte xai (Goo gle)	gemi ni-1.5 -pro	oo2 (lat est)	0.00 087 (<12 8k to kens) 0.00 167 (>= 1 28k t oken s)	0.00 327(< 12 8k c onte xt) 0.00 647(>= 1 28k cont ext)	yes				-			Y es	-	Y es	Y es	-	Y es	-	Y es	100
gcp- verte xai (Goo gle)	gemi ni-2. o-flas h	001 (lat est)	0.00 012	0.00 040	yes							ye s		ye s	ye s		ye s	ye s	ye s	100
gcp- verte xai (Goo gle)	gemi ni-2. o-flas h-lite	001 (lat est)	0.00 007	0.00 021	yes							ye s		ye s	ye s		ye s	ye s	ye s	100
aicor e-ale phal pha (sap- host ed)	aleph alpha -phar ia-1-7 b-con trol	202 411 (lat est)	0.00 018	0.00 027	yes (orch estra tion- only)							Y es								100
aicor e-op enso urce	deeps eek-a idee pseek -r1	202 502 (lat est)	0.00 060	0.00 305	yes(orch estra tion- only)					y es *						y e s *				10

^{*} Models with asterisks might be accessed from a cross-border location. This setup harmonizes the model offering across data centers and allows for load balancing and failovers, which help to mitigate data center outages. Data centers are selected based on model availability and data center proximity.

For example, AWS Bedrock Titan Embed Light in region EU10 is likely to be accessed within the EU10 region, but data centers outside of EU10 may be used for the purposes outlined.

The same model in region US10 uses only data centers within that region.

Compliance

It is your responsibility to ensure that your use of AI models made available on SAP Generative AI Hub comply with applicable laws, regulations, rules and corporate policies.

Note: this statement does not modify SAP's obligations under your agreement for the use of SAP Generative AI Hub.

Access Type

Models available on Generative AI Hub are accessed via remote providers, such as AWS Bedrock, or hosted by SAP AI Core.

SAP Hosted (sap-hosted): Model(s) hosted on SAP's own infrastructure, managed by SAP AI Core.

SAP Managed (sap-managed): Model(s) hosted on SAP's tenant isolated Hyperscaler infrastructure and managed by SAP AI Core.

Remote (provider e.g. AWS): Model(s) hosted and managed by Providers, accessed via SAP AI Core.

Model Versions

You have the following options when working with a model:

- You choose to always have the "latest" version of the model. The "latest" model version can be found in the table. When a version is deprecated, you
 will automatically be moved to the latest version of the model. Be aware that model behavior could change from version to version.
- You choose to work with a specific version of a model. In this case, you must check when the version will be deprecated and take appropriate steps.

For more information, see Create a Deployment for a Generative AI Model.

Model Availability, Deprecation, and Retirement Dates

Models are deprecated when more recent models or model versions are available with better performance. There may be models without a deprecation period before retirement. Please note that models marked as deprecated could mean there are newer, better and/or cheaper model alternatives available on Generative AI Hub. See "Suggested Replacements".

Models will be removed on the retirement date. API calls to these models will result in error responses.

We recommend that you avoid using deprecated models. If a model is deprecated, switch to newer models or model versions.

Note that deprecation or retirement dates may be adjusted. Please monitor this SAP Note for deprecation and retirement date changes.

The date format is YYYY-MM-DD.

Rate Limits

The rate limits in the table are requests made each minute to a specific model under an SAP AI Core tenant.

- AI Core tenancy is BTP subaccount based, multiple deployments for same model under same tenant/subaccount shares quota numbers shared in table.
- Limits are applied at tenant level based on certain assumptions such as the utilization of your global quota at a given point in time.
- When the limits are reached, clients will receive a 429 response code (too many requests).

Conversion Rates for GenAI Tokens

GenAI tokens correspond to blocks of 1,000 tokens of each model. The amount of GenAI tokens varies depending on the model used and the type of token (input or output). You can refer to the conversion rates listed above to determine how many GenAI tokens are consumed for each model and token type.

Use of orchestration modules may incur costs, in addition to the costs associated with completion calls. For more information on conversion rates, see SAP Note 3505347.

Recently Retired Models

These models have recently been retired and are no longer available.

Executable ID (Provider)	Model	Version	Suggested Replacement
aicore-opensource (self-hosted)	tiiuaefalcon-40b-instruct	N/A (latest)	metallama3.1-70b-instruct mistralaimixtral-8x7b-instruct-v01
azure-openai (Azure)	gpt-35-turbo	0613	gpt-40-mini
azure-openai (Azure)	gpt-35-turbo-16k	0613	gpt-40, gpt-4.1
aicore-opensource (sap-managed)	metallama3-70b-instruct	N/A (latest)	metallama3.1-70b-instruct
gcp-vertexai (Google)	textembedding-gecko	003	
gcp-vertexai (Google)	textembedding-gecko-multilingual	001	
gcp-vertexai (Google)	text-bison	002	gemini-2.0-flash
gcp-vertexai (Google)	gemini-1.0-pro	001	gemini-2.0-flash
gcp-vertexai (Google)	chat-bison	002	gemini-2.0-flash

SLA

Please note that the model response time depends on the token size, so we are unable to offer a latency SLA for Generative AI models.

| This document is referenced by

SAP Note/KBA	Component	Title
3566760		Region mapping between SAP BTP ABAP Environment and SAP AI Core
3505347	CA-ML-AIC	<u>Orchestration</u>
3248365	CA-ML-AIC	Central SAP Note for SAP AI Core